



AIAA3111 项目计划与提案

题目：基于 NASA 航天器遥测数据的上下文感知异常检测

(Context-Aware Anomaly Detection in NASA Spacecraft Telemetry Data)

任务类型：Anomaly Detection (异常检测) | 数据集：NASA SMAP/MSL

一、项目概述

1.1 研究背景

航天器在运行过程中会持续产生多变量遥测数据。设备故障、传感器异常或系统状态变化，往往最先体现为时间序列中的异常模式。及时发现这些异常，对航天器的运行监控和故障预警具有实际意义。因此，本项目面向的是一个真实的航天器状态监测问题，而非人为构造的数据挖掘示例。

1.2 任务定义

数据集包含多个遥测通道、仅含正常状态的训练数据、测试数据，以及官方标注的异常时间区间。我们将异常检测定义为：

利用正常遥测数据学习系统的正常模式，并识别测试数据中偏离该模式的时间点或时间区间。

1.3 标签定义

官方标注的异常区间可转换为逐时间点的标签：

$$y_t = \begin{cases} 1, & t \text{ 属于官方标注的异常区间} \\ 0, & \text{否则} \end{cases}$$

因此，本项目无需依赖人工注入的异常，可直接以数据集自带的标签作为 ground truth 评价模型。

1.4 方法概览

项目将对比统计方法、传统机器学习方法和时序深度学习方法：

- 滑动窗口 z-score；
- PCA 重构误差；
- Isolation Forest；
- LSTM / GRU Autoencoder（主要模型）；
- Transformer（时间允许时作为扩展）。

这些方法均从大量多变量数据中学习正常模式并发现偏离，符合数据挖掘课程对方法的要求。

1.5 与课程要求的对应关系

课程要求项目针对真实问题，在 classification、clustering、anomaly detection、pattern mining 中至少选择一类任务，并提交报告、代码、README、数据或下载说明、poster 及现场展示。本项目的对应关系如下：

课程要求	本项目对应内容
真实世界问题	NASA 航天器遥测异常监测
数据挖掘任务	Anomaly Detection
数据集	NASA SMAP/MSL
方法	z-score、PCA、Isolation Forest、LSTM/GRU Autoencoder
量化实验	Precision、Recall、F1、FPR、Detection Delay
报告	问题、数据、方法、实验、结果、局限性
代码和 README	数据下载、预处理、训练、测试及复现说明
Poster	问题、数据、方法、结果与结论

二、研究问题

1. 仅使用单个遥测变量，能否检测出官方标注的异常？
2. 同时使用多个变量，能否提升检测效果？
3. 引入时间窗口信息，是否优于只看当前时刻？
4. 哪种方法能在检测质量与误报率之间取得最佳平衡？
5. 哪种方法能更早发现异常事件？

核心对比设置：

单变量 *vs* 多变量 *vs* 多变量 + 时间窗口

三、实施计划

步骤 1：确认数据集与标签

下载 SMAP 和 MSL，并检查：

- 文件能否正常获取；
- 训练集与测试集的格式；
- 通道数量与序列长度；
- anomaly labels 的格式；
- 标签能否与测试数据正确对齐。

通过标准： 能画出至少一条正常序列和一条带异常区间的测试序列，且标签位置正确。

步骤 2：数据预处理

1. 检查缺失值和无效值；
2. 按通道归一化，且归一化参数仅由训练集计算；
3. 将连续序列切分为固定长度的窗口；
4. 将异常区间转换为 point-wise 标签和 window-level 标签。

窗口标签定义为：

$$y_i^{window} = 1 \quad \text{if} \quad \sum_{t \in W_i} y_t > 0$$

通过标准： 能输出格式统一的 X 、 y ，且训练、验证、测试数据之间没有时间泄漏。

步骤 3：建立 Baseline

先不训练复杂神经网络，完成三个基础方法：

滑动窗口 z-score

$$z_t = \frac{x_t - \mu_t}{\sigma_t}$$

当 $|z_t| > \tau$ 时判为异常。

PCA 重构误差

$$e_t = \|x_t - \hat{x}_t\|_2$$

Isolation Forest

基于多变量窗口特征检测孤立样本。

这一步的目的不是追求最高分，而是确认：标签与评价代码正确、模型能产生有效的异常分数、指标计算无误。

步骤 4：训练主要模型

主要模型为 LSTM 或 GRU Autoencoder，使用正常训练窗口学习重构：

$$X_{t-L:t} \rightarrow \hat{X}_{t-L:t}$$

异常分数为重构误差：

$$e_t = \|X_t - \hat{X}_t\|_2$$

阈值 τ 由验证集确定：

$$\hat{y}_t = 1(e_t > \tau)$$

若 LSTM/GRU 训练稳定，再考虑引入 Transformer 作为扩展；Transformer 不是项目能否完成

的前提。

步骤 5：统一评估与对比

以官方 anomaly labels 为 ground truth，计算：

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}$$

$$F1 = \frac{2PR}{P + R}, \quad \text{FPR} = \frac{FP}{FP + TN}$$

对于异常区间 $[t_s, t_e]$ ，检测延迟定义为：

$$\text{Delay} = \hat{t}_{first} - t_s$$

其中 $\hat{t}_{first}$ 为模型在该区间内首次报警的时刻。

同时报告两类结果：

- point-wise 指标；
- event-level 指标。

这样可以避免模型只命中异常区间中的个别点，却被误认为完整检测了整个事件。

步骤 6：整理项目成果

- 实验结果表；
- 方法对比图；
- 异常分数与真实标签的可视化；
- 错误案例分析；
- 项目报告与 poster；
- 代码与 README；
- 数据下载与运行说明。

四、可行性检查（开始实现前）

1. **数据可获取：** 确认 SMAP/MSL 能够下载，且不存在权限或链接问题。

2. **标签可对齐**：确认 anomaly intervals 能正确映射到测试序列的时间索引，否则后续 Precision、Recall、F1 均不可信。
3. **规模可运行**：先用少量通道或较短窗口跑通代码，再扩展到完整数据。LSTM/GRU Autoencoder 在 4 张 4090 上算力充足，无需一开始就使用多卡训练。
4. **Baseline 有效**：若 z-score、PCA、Isolation Forest 完全无法区分异常，应先排查数据和标签，而不是直接增加模型复杂度。
5. **评价合理**：异常数据类别极不平衡，不能只报告 accuracy，至少需报告 Precision、Recall、F1、FPR 和 Detection Delay。
6. **防止数据泄漏**：归一化参数、阈值和超参数只能由训练集或验证集确定，不得使用测试集标签调参。

五、基础提案（草稿）

项目标题： 基于 NASA 航天器遥测数据的上下文感知异常检测

项目简介：

本项目研究 NASA SMAP/MSL 航天器多变量遥测数据中的异常检测问题。数据集包含多个遥测通道、正常训练数据、测试数据以及官方标注的异常时间区间。我们将异常检测定义为：利用正常遥测数据学习系统的正常模式，并识别测试数据中偏离该模式的时间点或时间区间。

项目首先实现滑动窗口 z-score、PCA 重构误差和 Isolation Forest 等传统方法，随后使用 LSTM 或 GRU Autoencoder 建立时序模型。我们将比较单变量输入、多变量输入以及带时间窗口的多变量输入，考察上下文信息能否提升检测效果。模型输出将与官方 anomaly labels 对比，并采用 Precision、Recall、F1-score、False Positive Rate、事件检测率和 Detection Delay 进行评价。最终提交内容包括实验报告、代码、README、数据下载说明和 poster。

项目类型： Anomaly Detection

当前阶段目标：

现阶段不急于使用复杂模型，而是先依次验证以下四项：

数据可下载 → 标签可对齐 → Baseline 可运行 → 指标可计算

四项全部通过后，再开始训练 LSTM/GRU Autoencoder 并生成正式实验结果。